

**Московский Авиационный Институт
(Национальный Исследовательский Университет)**

Факультет: “Информационные технологии и прикладная математика”
Кафедра: 806 “Вычислительная математика и программирование”

**Отчет по лабораторной работе №7
по курсу «Нейроинформатика»**

Студент: Полей-Добронравова Амелия Вадимовна

Группа: М8О-407Б, № по списку 20.

Преподаватель: Аносова Н.П.

Дата: 27.12.2021

Итоговая оценка:

Подпись преподавателя:

Москва, 2021

Тема лабораторной: “Автоассоциативные сети с узким горлом”

Целью работы является исследование свойств автоассоциативных сетей с узким горлом, алгоритмов обучения, а также применение сетей для выполнения линейного и нелинейного анализа главных компонент набора данных.

Основные этапы работы:

1. Использовать автоассоциативную сеть с узким горлом для отображения набора данных, выделяя первую главную компоненту данных.
2. Использовать автоассоциативную сеть с узким горлом для аппроксимации кривой на плоскости, выделяя первую нелинейную главную компоненту данных.
3. Применить автоассоциативную сеть с узким горлом для аппроксимации пространственной кривой, выделяя старшие нелинейные главные компоненты данных.

20.


Эллипс: $a = 0.5$, $b = 0.5$, $\alpha = \pi/6$, $x_0 = 0.2$, $y_0 = -0.1$

Полярные уравнения

$$r = \frac{1}{\sqrt{\varphi}}, \quad \varphi \in [0.01, 2\pi]$$

Ход работы

Автоассоциативная сеть - многослойная нейронная сеть прямого распространения сигнала, обученная выдавать входные данные на выходе. В обучении автоассоциативной сети "учителем" является сама входная информация. Обычно сеть имеет скрытый слой меньшей размерности, который выделяет наиболее значимые признаки во входной информации. Автоассоциативные сети с таким слоем оказываются полезны при решении задач обработки данных высокой размерности, так как позволяют сократить объем данных.



Алгоритм Левенберга-Марквардта - метод оптимизации/обучения. Он занимается минимизацией функции

$$F(\vec{x}) = \|\vec{f}(\vec{x})\|^2 = \sum_{i=1}^m f_i^2(\vec{x}) = \sum_{i=1}^m (\varphi_i(\vec{x}) - \mathcal{F}_i)^2 \rightarrow \min$$

Направление поиска Левенберга — Марквардта определяется из системы:

$$[J^T(\vec{x}_k)J(\vec{x}_k) + \lambda_k I]\vec{p}_k = -J^T(\vec{x}_k)\vec{f}(\vec{x}_k),$$

где λ_k — некоторая неотрицательная константа, своя для каждого шага, I — единичная матрица.

$$\vec{x}_{k+1} = \vec{x}_k + \vec{p}_k.$$

J - матрица Якоби вектор-функции $f(x)$;

p - направление;

Выбор параметра λ_k можно осуществлять, делая его достаточным для монотонного спуска по функции невязки $F(x)$, то есть увеличивать параметр до тех пор, пока не

будет достигнуто условие $F(\vec{x}_{k+1}) < F(\vec{x}_k)$. Также его можно устанавливать исходя из отношения между фактическими изменениями вектор-функции $f(x)$ достигнутыми в результате пробных шагов, и ожидаемыми величинами этих изменений при интерполяции. Подобную процедуру построил Флетчер.

Также можно показать, что \vec{p}_k удовлетворяет условию:


$$\vec{p}_k = \arg \min_{\|\vec{p}\| \leq \Delta} \|J(\vec{x}_k)\vec{p} + \vec{f}(\vec{x}_k)\|,$$

где Δ — параметр, связанный с λ_k .


Результаты

Задание 1


Оранжевым цветом предсказания.




Компонента y:



Компонента X:





Задание 2



Так как передавалась компонента X , на участке, где несколько значений y соответствуют X , происходит подобие поиска золотой середины.

Задание 3



Выводы

Метод Левенберга-Марквардта является первым методом, основанным на идее доверительного региона. Сходится метод в большинстве случаев довольно быстро. Однако при минимизации функций общего вида выбирать сферу в качестве доверительного региона — вряд ли наилучший из возможных вариантов.

Автоассоциативные сети используются для понижения размерности данных.

Метод Левенберга-Марквардта не популярный, на Python есть только одна библиотека, поддерживающая данное решение.