МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ (НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ)

Институт №8 «Информационные технологии и прикладная математика» Кафедра 806 «Вычислительная математика и программирование»

Лабораторная работа №8 по курсу «Программирование графических процессоров»

Технология MPI и технология CUDA. MPI-IO

Выполнил: Полей-Добронравова

Амелия

Группа: 8О-407Б

Преподаватели: К.Г. Крашенинников,

А.Ю. Морозов

Условие

Цель работы. Совместное использование технологии MPI и технологии CUDA. Применение библиотеки алгоритмов для параллельных расчетов Thrust. Реализация метода Якоби. Решение задачи Дирихле для уравнения Лапласа в трехмерной области с граничными условиями первого рода. Использование механизмов MPI-IO и производных типов данных.

Требуется решить задачу описанную в лабораторной работе №7, используя возможности графических ускорителей установленных на машинах вычислительного кластера. Учесть возможность наличия нескольких GPU в рамках одной машины. На GPU необходимо реализовать основной расчет. Требуется использовать объединение запросов к глобальной памяти. На каждой итерации допустимо копировать только граничные элементы с GPU на CPU для последующей отправки их другим процессам. Библиотеку Thrust использовать только для вычисления погрешности в рамках одного процесса.

Все **входные-выходные данные** и **варианты заданий по межпроцессорному взаимодействию** совпадают с входными-выходными данными и вариантами заданий из лабораторной работы №7.

Запись результатов в файл должна осуществляться параллельно всеми процессами. Необходимо создать производный тип данных, определяющий шаблон записи данных в файл. **Варианты** конструкторов типов:

- 1. MPI_Type_create_subarray
- 2. MPI_Type_hvector
- 3. MPI_Type_hindexed

Допускается двойное использование графической памяти относительно размера блока обрабатываемого одним процессом.

Вариант 1.

Программное и аппаратное обеспечение

Компилятор nvcc версии 7.0(g++ версии 4.8.4) на 64-x битной Ubuntu 14.04 LTS.

Параметры графического процессора:

Compute capability: 6.1 Name: GeForce GTX 1050

Total Global Memory : 2096103424 Shared memory per block : 49152

Registers per block: 65536

Max threads per block : (1024, 1024, 64) Max block : (2147483647, 65535, 65535)

Total constant memory: 65536

Multiprocessors count: 5

Метод решения

Часть решения базируется на 7 ЛР. Отличающиеся моменты:

Копирование граничных значений блоков сетки в буферы для обмена осуществляется с помощью ядер GPU. Максимальную погрешность в одном процессе я ищу автоматически с помощью библиотеки Thrust, далее для проверки по всем процессам собираю их с помощью MPI Allgather.

Каждый процесс записывает свой итоговый результат в общий файл с результатом работы программы. Перед записью в выходной файл формируется буферный массив с выходными данными, далее с помощью возможностей МРІ описывается способ парсинга из данного буфера в выходной файл.

Описание программы

Макросы с именами **next_(индексы)** - макросы для итерации по координатам буферов обмена во время параллельной обработки на GPU.

idx - макрос определения индекса записи в буфер для последующей записи в файл.

import_(координата) - функции GPU параллельного копирования граничных значений блоков сетки в буферы для обмена.

export_(координата) - функции GPU параллельного копирования граничных значений блоков сетки из буферов обмена.

new_grid(...) - функция GPU параллельного пересчета значений после получения новых границ.

Результаты

Имеет смысл сравнивать результат с вариантом в 7ЛР, чтобы доказать эффективность совместного использования MPI и CUDA.

Размер общей сетки тестов ниже не меняется.

Сетка / Расчет	Результат на MPI+CUDA, мс	Результат на МРІ, мс	на СРИ, мс
1 1 1 / 40 40 40	5680	19861	9843
2 2 2 / 20 20 20	38510	4943	9952
2 2 4 / 20 20 10	97931	6224	9890

Время работы стало хуже даже чем на СРU.

Код программы для СРU:

```
#include <iostream> #include <string.h>
#include <chrono>
#include <fstream>
#include <algorithm> using namespace std;
#include <stdlib.h> using namespace std::chrono;
#include <iomanip>
```

```
const int ndims = 3;
                                               cin >> u[down] >> u[up];
const int ndims x 2 = 6;
                                               cin >> u[left] >> u[right];
                                                cin >> u[front] >> u[back];
double u next(double ux0, double ux1,
                                                cin >> u0;
double uy0, double uy1, double uz0,
double uz1, double h2x, double h2y,
                                               auto start = steady_clock::now();
double h2z){
   double ans = (ux0 + ux1) * h2x;
                                               double max diff = 0.0;
   ans += (uy0 + uy1) * h2y;
   ans += (uz0 + uz1) * h2z;
   return ans;
                                            dimens[dir x]*blocks[dir x];
}
                                            dimens[dir y]*blocks[dir y];
double max_determine(double
                                val1,
                                                                 int
double val2, double curr max) {
                                            dimens[dir z]*blocks[dir z];
   double diff = val1 - val2;
   diff = diff < 0.0 ? -diff : diff;</pre>
                                                int sizex = nx + 2;
                                                int sizey = ny + 2;
     return diff > curr max ? diff :
                                               int sizez = nz + 2;
curr_max;
                                                double h2x, h2y, h2z;
                                                h2x = 1[dir x] / ((double)nx);
                                                h2y = 1[dir y] / ((double)ny);
void print line(ostream& os, double*
                                               h2z = l[dir z] / ((double)nz);
line, int size) {
   for(int i = 0; i < size; ++i){
      os << line[i] << " ";
                                               h2x *= h2x;
   }
                                                h2y *= h2y;
}
                                                h2z *= h2z;
                                                            double denuminator =
int main(int argc, char **argv){
                                            2.0*(1.0/h2x + 1.0/h2y + 1.0/h2z);
std::ios base::sync with stdio(false);
                                                      h2x = 1.0 / (denuminator *
   std::cin.tie(nullptr);
                                            h2x);
   int dimens[ndims], blocks[ndims];
                                                      h2y = 1.0 / (denuminator *
   double l[ndims];
                                            h2y);
                                                      h2z = 1.0 / (denuminator *
   double u[ndims x 2];
   double u0, eps;
                                            h2z);
   string path;
                                               }
   enum orientation{
                                                double* buffer0 = new double[sizex
      left = 0, right,
                                            * sizey * sizez];
       front, back,
                                                double* buffer1 = new double[sizex
       down, up,
                                            * sizey * sizez];
   } ;
   enum direction{
                                                fill_n(buffer0, sizex * sizey *
       dir x = 0,
                                            sizez, u0);
       dir_y,
       dir z
                                                int orr = 0;
                                                for(int i = 0; i < sizex; i += nx
   };
                                            + 1, ++orr) {
         cin >> dimens[dir x] >>
                                                     for(int j = 1; j < ny + 1;
dimens[dir y] >> dimens[dir z];
                                            ++j){
                                                        for (int k = 1; k < nz + 1;
         cin >> blocks[dir x] >>
blocks[dir y] >> blocks[dir z];
                                            ++k) {
   cin >> path;
                                                                 buffer0[i + (j +
   cin >> eps;
                                            k*sizey)*sizex] = u[orr];
      cin >> l[dir_x] >> l[dir_y] >>
                                                                 buffer1[i + (j +
l[dir_z];
                                            k*sizey)*sizex] = u[orr];
```

```
- 1 + k*sizey)*sizex], buffer0[i + (j
                                          + 1 + k*sizey)*sizex], buffer0[i + (j
   }
                                          + k*sizey - sizey)*sizex], buffer0[i +
                                           (j + k*sizey + sizey)*sizex], h2x,
    for(int j = 0; j < sizey; j += ny
                                          h2y, h2z);
                                                                    max_diff =
+ 1, ++orr) {
                                          max_determine(buffer0[i + (j +
        for (int k = 1; k < nz + 1;
                                          k*sizey)*sizex], buffer1[i + (j +
++k) {
                                          k*sizey)*sizex], max_diff);
           for (int i = 1; i < nx + 1;
++i) {
                                                         }
                    buffer0[i + (j +
                                                      }
k*sizey)*sizex] = u[orr];
                                                  }
                    buffer1[i + (j +
k*sizey)*sizex] = u[orr];
                                                  double* temp = buffer0;
                                                  buffer0 = buffer1;
         }
                                                  buffer1 = temp;
       }
                                              }while(max diff >= eps);
    for(int k = 0; k < sizez; k += nz
                                              ofstream fout(path, ios::out);
+ 1, ++orr) {
                                                   fout << std::scientific <<</pre>
         for (int j = 1; j < ny + 1;
                                          std::setprecision(7);
++j){
           for (int i = 1; i < nx + 1;
                                              for (int k = 1; k \le nz; ++k) {
                                                 for(int j = 1; j <= ny; ++j){
++i){
                                                       for(int i = 1; i <= nx;
                    buffer0[i + (j +
k*sizey)*sizex] = u[orr];
                                          ++i) {
                    buffer1[i + (j +
                                                          fout << buffer0[i + (j</pre>
k*sizey)*sizex] = u[orr];
                                           + k*sizey)*sizex] << " ";
                                                     }
           }
       }
                                                  }
   }
                                              fout << endl;
   do{
                                              delete[] buffer0;
       \max diff = 0.0;
                                              delete[] buffer1;
       for (int k = 1; k \le nz; ++k) {
                                             fout.close();
            for(int j = 1; j \le ny;
                                              auto end = steady clock::now();
++j){
                 for(int i = 1; i <= cout << "Inference time: ";</pre>
nx; ++i) {
                                                                   cout
                     k*sizey)*sizex] = u next(buffer0[i - 1
+ (j + k*sizey)*sizex], buffer0[i + 1
                                          << endl;
+ (j + k*sizey)*sizex], buffer0[i + (j
                                             return 0;
```

Выводы

- 1. Возможность записывать результат работы из нескольких процессов в один файл, избегая пересылки в один (главный) процесс для записи, сокращает время работы программы, но усложняет ее написание.
- 2. Замедление работы программы можно объяснить тем, что для использования CUDA приходится постоянно перемещать память с хоста на видеокарту, что является долгим процессом. Лишнее подтверждение того, что не стоит использовать вычисления на видеокарте, при которых требуется частый обмен данными.