

Московский Авиационный Институт
(Национальный Исследовательский Университет)

Кафедра 806 «Вычислительная информатика и программирование»
Факультет: «Информационные технологии и прикладная математика»

Лабораторная работа
по курсу «Параллельные и распределенные вычисления»

Группа:	М8О-114М-22
Студент:	Полей-Добронравова Амелия Вадимовна

Москва, 2022

Задание

1. Обучить модели фреймворка `pytorch` на параллельных вычислителях с помощью технологии `mpi`.
2. Переслать разные куски датасета для этих нейронных сетей для обучения.
3. Переслать данные для предсказания разным процессам с разными нейронными сетями.
4. В управляющем процессе сделать предсказание ансамблевым методом.

Решение

Решение представлено тремя файлами: `mpi_pytorch.ipynb` с демонстрацией решения, `train.py` - файл для обучения ансамбля моделей, `test.py` - файл для тестирования ансамбля моделей.

В **`mpi_pytorch.ipynb`** продемонстрирована загрузка датасета с фотографиями CIFAR10, выведены несколько примеров из датасета, представлены примеры запуска обучения и тестирования ансамбля моделей. Запуск обучения и тестирования производится на 4 процессах с помощью команды `mpirun`.

```
!mpirun -n 4 python3 train.py
!mpirun -n 4 python3 test.py
```

Ансамбль моделей представляет из себя несколько сверточных сетей VGG16.

В **`train.py`** создана отдельная функция для обучения одной нейросетевой модели, остальные действия происходят в блоке `main`. Обучение длится всего одну эпоху, модели не успевают достаточно обучиться, но для демонстрации интеграции `pytorch` и `mpi` не требуется обучать модели на высокое качество.

В управляющем процессе с рангом 0 обучающий датасет делится на число частей, равное числу процессов - 1. Далее каждому процессу отправляется своя часть датасета с помощью команды `comm.send()`.

В обычном процессе создается загрузчик данных для своей части датасета, полученной с помощью команды `comm.recv()`, производится обучение и

сохраняются веса модели в отдельный файл, содержащий в названии ранг своего процесса.

В **test.py** управляющий процесс с рангом 0 отправляет один образец из тестового набора данных всем другим процессам. Потом получает Предсказание от каждого, считает среднее арифметическое по процентам каждого класса и выдает класс с максимальным процентом вероятности.

Код

train.py

```
import torch

import torchvision

import torchvision.transforms as transforms

import torch.nn as nn

import torch.nn.functional as F

import torch.optim as optim

from torchvision.models import vgg16

from mpi4py import MPI

from tqdm import tqdm

def train(my_rank, net, criterion, optimizer, trainloader):

    running_loss = 0.0

    it = 0

    for i, data in tqdm(enumerate(trainloader, 0)):

        if it == 5:

            break

        inputs, labels = data

        optimizer.zero_grad()

        outputs = net(inputs)

        loss = criterion(outputs, labels)
```

```

        loss.backward()

        optimizer.step()

    running_loss += loss.item()

    it += 1

    print(f'model: {my_rank} \n loss: {running_loss / it}\n')

    running_loss = 0.0

    return net

if __name__ == "__main__":

    comm = MPI.COMM_WORLD

    my_rank = comm.Get_rank()

    p = comm.Get_size()

    img_size = (300, 450)

    transform = transforms.Compose(

        [transforms.Resize(img_size),

        transforms.ToTensor(),

        transforms.Normalize((0.5, 0.5, 0.5), (0.5, 0.5, 0.5))]])

    if my_rank == 0:

        trainset = torchvision.datasets.CIFAR10(root='./data', train = True,
download=False, transform=transform)

        #разделяем датасет на p-1 частей

        length1 = len(trainset) // (p - 1)

        l = [length1 for i in range(p - 2)]

        l.append(len(trainset) - (p - 2) * length1)

        parts = torch.utils.data.random_split(trainset, l)

        for i in range(len(parts)):

            comm.send(parts[i], dest = i + 1)

```

```

else:

    #создаем свой экземпляр нейросети

    net = vgg16(pretrained=False)

    num_fts = net.classifier[6].in_features

    net.classifier[6] = nn.Linear(num_fts, 10)


    criterion = nn.CrossEntropyLoss()

    optimizer = optim.SGD(net.parameters(), lr=0.001, momentum=0.9)


    #получаем свой кусок датасета

    dataset_part = comm.recv(source = 0)


    #создаем загрузчик датасета

    batch_size = 4

    trainloader = torch.utils.data.DataLoader(dataset_part,
batch_size=batch_size, shuffle=True, num_workers=2)


    #обучаем свой экземпляр нейросети

    net = train(my_rank, net, criterion, optimizer, trainloader)


    #сохраняем обученную модель

    PATH = f'./net_{my_rank}.pth'

    torch.save(net.state_dict(), PATH)

    MPI.Finalize

```

test.py

```

import torch

import torchvision

import torch.nn as nn

import torchvision.transforms as transforms

from torchvision.models import vgg16

from mpi4py import MPI

```

```

classes = ('plane', 'car', 'bird', 'cat',
           'deer', 'dog', 'frog', 'horse', 'ship', 'truck')

if __name__ == "__main__":
    comm = MPI.COMM_WORLD

    my_rank = comm.Get_rank()

    p = comm.Get_size()

    img_size = (300, 450)

    transform = transforms.Compose(
        [transforms.Resize(img_size),
         transforms.ToTensor(),
         transforms.Normalize((0.5, 0.5, 0.5), (0.5, 0.5, 0.5))])

    if my_rank == 0:
        #итерация по тестовому датасету

        testset = torchvision.datasets.CIFAR10(root='./data', train=False,
        download=False, transform=transform)

        batch_size = 1

        testloader = torch.utils.data.DataLoader(testset, batch_size=batch_size,
        shuffle=True, num_workers=2)

        it = 0

        for i, data in enumerate(testloader, 0):

            if it == 5:
                break

            inputs, labels = data

            #отправить моделям на предсказание

            for i in range(1, p):
                comm.send(inputs, i)

            preds = []

            #получить предсказания и сделать ансамбль голосов

```

```

        for procid in range(1, p):

            preds.append(comm.recv(source = procid))

            #среднее арифметическое

            buf = torch.zeros_like(preds[0])

            for p1 in preds:

                for idx in range(len(p1)):

                    buf[idx] += p1[idx]

            for idx in range(len(buf)):

                buf[idx] /= len(preds)

            it += 1

            print('Predicted: ', ' '.join(f'{classes[torch.argmax(buf)]}')

            break

    else:

        #загрузить свою модель

        PATH = f'./net_{my_rank}.pth'

        net = vgg16(pretrained=False)

        num_fts = net.classifier[6].in_features

        net.classifier[6] = nn.Linear(num_fts, 10)

        net.load_state_dict(torch.load(PATH))

        #получить предсказание по одной картинке

        image = comm.recv(source = 0)

        outputs = net(image)

        comm.send(outputs, dest = 0)

    MPI.Finalize

```

Вывод

С помощью mpi можно просто запараллелить обучение нейросетевых моделей, что особенно актуально: нейросетевые вычисления очень тяжеловесные и долгие.